

گزارش فنی پروژه

ارزیابی مدل‌های تشخیص خودکار گفتار در حوزه کنترل ترافیک هوایی

ATC-ASR Benchmark — گزارش نهایی

مجری پروژه: علیرضا حقی

تاریخ تهیه گزارش: خرداد ۱۴۰۵

مجموعه ارزیابی: ATCO2 Corpus 1h | تعداد نمونه: ۸۷۱


۱. خلاصه اجرایی

این گزارش نتایج یک پایپ‌لاین کامل از صوت تا متن (End-to-End) برای تشخیص خودکار گفتار در حوزه کنترل ترافیک هوایی (ATC-ASR) را ارائه می‌دهد. ارزیابی روی مجموعه داده استاندارد ATCO2 Corpus 1h با 871 نمونه صوتی انجام شده است.

بهترین نتیجه با مدل `jacktol/whisper-large-v3-finetuned-for-ATC` و `beam size=5` به دست آمد: $WER = 6.96\%$ و $CER = 3.76\%$. این عملکرد با نرمال‌سازی متنی اختصاصی ATC (کاهش 2.01% از WER خام) تقویت شده است. از 871 نمونه، 573 نمونه به‌صورت کاملاً صحیح رونویسی شدند.

۲. معماری پایپ‌لاین اجرایی

پایپ‌لاین طراحی شده دارای مراحل زیر است:



۲.۱ مدیریت VAD

ماژول VAD با مدل Silero پیاده‌سازی شده است. در حالت فعال، بخش‌های سکوت حذف و گفتار خالص استخراج می‌شود. مقایسه `run1` (بدون VAD، $WER=6.96\%$) و `run6` (با VAD، $WER=12.66\%$) نشان می‌دهد که در این dataset کوتاه‌بودن نمونه‌ها با VAD افت کیفیت ایجاد می‌کند؛ این رفتار مستند شد.

۲.۲ پشتیبانی از مدل‌های متعدد

پایپ‌لاین از هر دو معماری Whisper (encoder-decoder) و Wav2Vec2-CTC پشتیبانی می‌کند. برای Whisper پارامترهای `num_beams` و `temperature` قابل تنظیم هستند. مدل‌ها در `cache` نگهداری می‌شوند تا از بارگذاری مکرر جلوگیری شود.

۲.۳ پایداری و Reproducibility

تمامی تنظیمات هر اجرا در فایل‌های `(configs/config_run*.json)` JSON ذخیره می‌شوند. پیش‌بینی‌ها نیز در `predictions/predictions_run*.json` نوشته می‌شوند. در صورت وجود فایل روی دیسک، اجرا از نو انجام نمی‌شود و نتایج کش بارگذاری می‌گردند.

۳. نتایج Benchmark روی ۱h ATCO₂ Corpus

جدول زیر نتایج کامل 6 پیکربندی مختلف را روی 871 نمونه از مجموعه آزمون ATCO₂ نشان می‌دهد. معیارهای S (جایگزینی)، D (حذف) و I (درج) از طریق تابع `process_words` کتابخانه `jiwer` محاسبه شده‌اند.

Perfect	I	D	S	CER	WER	مدل / پیکربندی
573	86	189	477	3.76%	6.96%	jacktol-whisper-large-v3-ATC beam=5
560	86	204	513	4.06%	7.44%	jacktol-whisper-large-v3-ATC beam=1 (greedy)
533	147	201	536	5.54%	8.19%	jacktol-whisper-medium.en-ATC beam=1 (greedy)
77	982	935	2144	24.09%	37.60%	fjmgAI-whisper-large-v3-ATC beam=1
27	260	1224	3443	23.18%	45.62%	XLS-R-300M UWB-ATCC+ATCOSIM (CTC)
342	101	618	648	9.24%	12.66%	jacktol-whisper-large-v3-ATC beam=5 + VAD

WER=0: نمونه‌هایی با Perfect: درج | I: حذف | D: جایگزینی | S: *S

۳.۱ تحلیل نتایج

برترین مدل (jacktol/whisper-large-v3-ATC با beam=5) به WER=6.96% رسید که با توجه به چالش‌های صوتی حوزه ATC (نویز محیطی، لهجه‌های متنوع، الفبای هجایی) نتیجه‌ای قابل توجه است. افزایش beam_size از 1 به 5 کاهش 0.48% در WER را به همراه داشت.

مدل fjmgAI/whisper-large-v3-ATC با WER=37.60% عملکرد ضعیفی داشت که نشان‌دهنده عدم تطابق توزیع داده‌های fine-tune آن با ATCO2 است. مدل XLS-R-300M با WER=45.62% کمترین دقت را نشان داد که ناشی از محدودیت معماری CTC و عدم fine-tune کافی است.

تفاوت چشمگیر بین WER میانه (0.0%) و WER میانگین (7.88%) برای بهترین مدل نشان می‌دهد که بیشتر خطاها در تعداد محدودی از نمونه‌های دشوار متمرکز است.

۴. نرمال‌سازی متنی اختصاصی ATC

یکی از چالش‌های اصلی در ارزیابی ASR برای ATC، ناسازگاری شکل بیان عدد و مخففات است. برای رفع این مشکل، دو تابع نرمال‌سازی پیاده‌سازی شد:

تابع **normalize_for_wer** — برای محاسبه معیار WER/CER به کار می‌رود. اعداد به حروف تبدیل می‌شوند.

تابع **normalize_for_display** — برای نمایش انسانی، مخففات استاندارد ATC را ایجاد می‌کند.

تأثیر نرمال‌سازی بر WER:

پس از نرمال‌سازی: WER 6.96 → بدون نرمال‌سازی: WER 8.98
(بهبود: 2.01-)

جدول زیر نمونه‌هایی از رفتار نرمال‌سازی را نشان می‌دهد:

خروجی normalize_for_display	خروجی normalize_for_wer	ورودی اصلی (خام)
descend FL180	descend flight level one eight zero	descend flight level one eight zero
squawk 4567	squawk four five six seven	squawk four five six seven
contact 127.4	contact one two seven decimal four	contact one two seven decimal four
RWY28L	runway two eight left	runway two eight left
climb to FL350	climb to flight level three five zero	climb to flight level three five zero
niner thousand feet	nine thousand feet	niner thousand feet
heading 240	heading two four zero	heading two four zero

قواعد پیاده‌سازی شده در نرمال‌سازی شامل موارد زیر است:

- `niner` → `nine` (استاندارد ICAO برای عدد ۹)
- `fife` → `five`, `tree` → `three`, `alfa` → `alpha` (جایگزینی واژگان مشابه صوتی)
- `FL180` → `flight level one eight zero` (بسط مخففات)
- `RWY28L` → `runway two eight left` (بسط شناسه‌های باند)
- `127.4` → `one two seven decimal four` (بسط فرکانس)
- نرمال‌سازی نام ایرلاین‌های رایج (`RyanAir`، `SpeedBird` و ...)

۵. تحلیل خطا — بررسی ۲۰ نمونه واقعی

برای تحلیل خطا، 35 نمونه از نمونه‌هایی با بالاترین WER انتخاب و نوع خطا (S: جایگزینی، D: حذف)، دسته‌بندی و شدت آن مشخص شد. از این میان ۲۰ نمونه شاخص در جدول زیر ارائه می‌شود.

۵.۱ توزیع خطاها

از 35 خطای ثبت‌شده: 27 S (Substitution) مورد، 8 D (Deletion) مورد

دسته‌بندی: 2 command | 3 number | 30 other

شدت: 5 moderate | 30 minor

۵.۲ جدول ۲۰ خطای شاخص

#	نوع	دسته	شدت	مرجع (REF)	فرضیه (HYP)	کلمه REF	کلمه HYP	توضیح / راهکار
1	S	other	minor	ready to touchdown	aeroflot nine two touch down	ready	two	کیفیت صوتی / لهجه
2	S	other	minor	number one golf bravo	level one four three airfrance bravo	number	level	کیفیت صوتی / لهجه
3	S	other	minor	number one golf bravo	level one four three airfrance bravo	golf	airfrance	کیفیت صوتی / لهجه
4	S	other	minor	merci au plaisir aurevoir	aeroflot two zero papa	merci	aeroflot	کیفیت صوتی / لهجه
5	S	other	minor	hotel echo xray	further approach	hotel	further	کیفیت صوتی / لهجه

#	نوع	دسته	شدت	مرجع (REF)	فرضیه (HYP)	کلمه REF	کلمه HYP	توضیح / راهکار
6	D	other	minor	hotel echo xray	further approach	xray	[حذف]	کیفیت صوتی / لهجه
7	S	other	minor	good night	is that	good	is	کیفیت صوتی / لهجه
8	S	other	minor	jetstar nine twelve	eight seven one twelve	jetstar	seven	کیفیت صوتی / لهجه
9	S	other	minor	beste schone heli oscar zulu	thats the short now heli oscar zulu	beste	short	کیفیت صوتی / لهجه
10	S	other	minor	c est rentre you may leave frequency merci bon soiree	three one three your maintaining frequency merci bon sorry	c	three	کیفیت صوتی / لهجه
11	D	other	minor	c est rentre you may leave frequency merci bon soiree	three one three your maintaining frequency merci bon sorry	leave	[حذف]	کیفیت صوتی / لهجه
12	S	other	minor	c est rentre you may leave frequency merci bon soiree	three one three your maintaining frequency merci bon sorry	bonne	bon	کیفیت صوتی / لهجه
13	S	command	moderate	frequency change approved a toute a l heure	sequency change approved at hotel	frequency	sequency	واژگان ATC — نیاز به LM

#	نوع	دسته	شدت	مرجع (REF)	فرضیه (HYP)	کلمه REF	کلمه HYP	توضیح / راهکار
14	D	other	minor	frequency change approved a toute a l heure	sequency change approved at hotel	a	[حذف]	کیفیت صوتی / لهجه
15	S	other	minor	tower good day rex sixty four sixty four sixty four	target airx sixty four six zero	tower	target	کیفیت صوتی / لهجه
16	D	other	minor	tower good day rex sixty four sixty four sixty four	target airx sixty four six zero	day	[حذف]	کیفیت صوتی / لهجه
17	S	number	moderate	tower good day rex sixty four sixty four sixty four	target airx sixty four six zero	sixty	six	ATC در اعداد در حیاتی‌اند
18	S	number	moderate	three five tango hotel alpha whiskey	cleared touch and go hotel alpha whiskey	three	touch	ATC در اعداد در حیاتی‌اند
19	S	command	moderate	runway two five cleared touch and go	runway two five csa echo tango	cleared	csa	واژگان ATC — نیاز به LM
20	S	other	minor	say again the departure we for us	thank you the departure is before us	say	thank	کیفیت صوتی / لهجه

۵.۳ تحلیل الگوهای خطا

اکثریت خطاها (86%) در دسته other قرار می‌گیرند. این به معنای خطاهایی است که ناشی از کیفیت صوتی، نویز پس‌زمینه رادیویی، لهجه‌های اروپایی (فرانسه، آلمانی، هلندی) و همپوشانی ارتباطی است. این خطاها با بهبود پیش‌پردازش صوت (فیلتر نویز، VAD بهتر) کاهش می‌یابند.

خطاهای دسته command (مانند frequency → sequence و cleared → csa) نشان می‌دهند که مدل در برخی موارد واژگان فیکس ATC را به‌درستی تشخیص نمی‌دهد. استفاده از Language Model اختصاصی ATC یا Hot-word boosting می‌تواند این خطاها را به‌طور مؤثر کاهش دهد.

خطاهای عددی (مانند sixty → six) در ATC بحرانی هستند زیرا اشتباه در ارتفاع، هدینگ یا فرکانس می‌تواند منجر به خطر پرواز شود. نرمال‌سازی دقیق اعداد و LM محدودکننده برای این دسته ضروری است.

۶. Artifacts و مستندات Reproducibility

پروژه دارای اقلام تحویلی زیر است:

- **ATC_Benchmark_Colab.ipynb** — نوت‌بوک کامل Google Colab شامل تمامی مراحل پایپ‌لاین
- **benchmark_results.json** — نتایج کامل WER/CER/S/D/I برای ۶ پیکربندی
- **normalization_report.json** — گزارش تأثیر نرمال‌سازی با مثال‌های before/after
- **error_analysis.json / .txt** — تحلیل خطا به فرمت ماشین‌خوان و انسانی
- **execution_log.json** — لاگ اجرایی شامل timestamp، dataset، مدل و نتایج
- **configs/config_run*.json** — تنظیمات کامل هر اجرا برای تکرارپذیری
- **predictions/predictions_run*.json** — پیش‌بینی کامل هر نمونه (REF/HYP/WER/CER)

۶.۱ راهنمای اجرا

برای اجرای مجدد پایپ‌لاین:

۱. نوت‌بوک را در Google Colab باز کنید.

۲. Runtime → Run all را اجرا کنید (نیاز به GPU T4 یا A100).

۳. نتایج به Google Drive در مسیر MyDrive/atc_asr_output/ ذخیره می‌شوند.

۴. برای اجرای مجدد با نرمال‌سازی جدید، فقط سلول

Re-normalize را اجرا کنید.

۵. وابستگی‌ها در اولین سلول به‌صورت خودکار نصب می‌شوند.

۷. نتیجه‌گیری و پیشنهادات

این پروژه یک پایپ‌لاین End-to-End قابل اجرا و تکرارپذیر برای ATC-ASR ارائه داده است. بهترین مدل ارزیابی شده (jacktol/whisper-large-v3-ATC) با $WER=6.96\%$ روی مجموعه آزمون ATCO2 نتایج قابل توجهی نشان داد. نرمال‌سازی اختصاصی ATC نقش معناداری در بهبود دقت ارزیابی داشت.

پیشنهادهای برای مراحل بعدی:

- Fine-tune اختصاصی روی داده‌های فارسی یا داده‌های محلی مرکز کنترل با معماری‌های نوین.